

SCTE-R：从 5 mm 胸部 CT 恢复肺气肿定量

结果报告 | 2026-09-18 | 外部验证 444 例（外院队列，两家厂商） | 训练队列 203 例（本院，独立）

一句话结论。已有的厚层→薄层重建方法提升图像质量，但不改善肺气肿定量的一致性；本

文找到了原因（确定性回归的最优解是一个恒定的整体密度平移），并给出在无薄层设备、无

本地配对数据条件下即可使用的解法。在 444 例外部队列上，LAA-950 与 LAA-910 的系统

偏差降到 0.3 个百分点以内，Perc15 偏差从已有方法的 +19~+24 HU 降到 +2.5 HU。

一、三项贡献

贡献一：一个此前未被报道的评价缺口

厚→薄重建的图像质量提升不转化为定量一致性。这一点在两个相互独立的数据集上一致成立：

- 外部临床队列（444 例，真实疾病负荷）：**CTHNet 的 PSNR 比 Lanczos 高 2.0 dB，而两者 LAA-950 的偏差相差 0.07 个百分点（-4.48 对 -4.41 pp）——图像质量的提升没有带来任何定量上的改善。
- 公开数据（50 例整卷）：**三种已发表方法的 PSNR 均在 33 dB 以上，比 Lanczos 插值高约 3 dB；三者的 LAA-950 偏差却均略差于插值（-0.82/-0.90/-0.86 对 -0.78 pp），方向一致。

可安全主张的统一表述：**已发表的厚→薄重建方法在密度定量一致性上不优于简单插值，尽管它们在图像质量指标上有 2-3 dB 的优势。**

这个缺口为什么至今没被报道。该领域通用的公开基准，其参考 LAA-950 平均值仅为 1.2%——本质上是一个无肺气肿人群。在这样的队列上，各方法的定量误差差异都在 0.1 个百分点量级，失效不可见。只有在具有真实疾病负荷的临床队列（LAA-950 $7.8 \pm 8.2\%$ ）上，同一失效才被放大到 4.5 个百分点。**评估数据集的疾病负荷过低，本身就是这一缺口长期未被发现的原因。**

贡献二：机制解释

本文给出了原因：在该逆问题上，**确定性回归的最优解是一个全局 HU 位移**。在 444 例外部数据上实测该位移为 **-16.32 ± 0.65 HU**——标准差仅 0.65 HU，说明它 是一个常数而非随机误差。把 LAA/Perc 直接写入损失函数不改变这个位移量。

阈值型指标（LAA 是"低于 -950 HU 的体素占比"）恰恰对这一个自由度最敏感，因此 **像素级最优与定量最优在本任务上不是同一个解**。这把贡献一从一次观察升级为可预测 的结论：任何只以像素误差为目标的方法都会收敛到这个解上。

贡献三：可部署的解法与无参考的站点闸门

SCTE-R 在残差空间做流匹配采样，恢复被回归抹平的实质纹理；并附带一个 **不需要 1 mm 参考**即可计算的效度判据——利用前向算子的均值保持性，可在部署现场 直接估计重建的整体密度位移，用于判断模型对本站点数据是否胜任。

二、主要结果

表 1 外部验证队列的定量一致性（n = 444，两家厂商、两种重建核）

方法	LAA-950			LAA-910			Perc15	Perc10
	偏差	95% 一致性	CCC	偏差	95% 一致性	CCC	偏差	偏差 (HU)
	(pp)	界		(pp)	界		(HU)	
Lanczos 插值	-4.41	-12.32 ~ +3.50	0.689	-7.30	-14.59 ~ -0.01	0.841	+23.5	+26.8
CTHNet	-4.48	-12.80 ~ +3.84	0.682	-5.98	-13.12 ~ +1.17	0.889	+19.3	+23.8
SCTE-R（零样本）	-0.26	-5.61 ~ +5.08	0.933	-0.32	-4.85 ~ +4.22	0.986	+2.5	+2.0
SCTE-R（站点适	+1.04	-3.18 ~	0.948	+1.72	-3.08 ~	0.978	—	—

配) +5.26 +6.52

参考值取自同次采集的 1 mm 重建：LAA-950 = 7.82 ± 8.21%， LAA-910 = 19.72 ± 14.42%， Perc15 = -911.2 ± 43.3 HU。偏差 = 重建值 - 参考值； 一致性界 = 偏差 ± 1.96 SD，即 95% 的个体误差所落的区间。

请注意表中两条基线：它们的 LAA-950 偏差相差 0.07 pp，而 PSNR 相差 2.0 dB。

表 2 公开数据上的同一现象（n = 50 整卷，参考 LAA-950 = 1.21 ± 1.14%）

方法	PSNR (dB)	偏差 (pp)	MAE (pp)	CCC
CTHNet (npj Digit Med 2024)	33.44	-0.82	0.82	0.152
TVSRN (MICCAI 2022)	33.17	-0.90	0.90	0.068
I3Net (TMI 2024)	33.22	-0.86	0.86	0.100
Lanczos 插值	30.27	-0.78	0.78	0.259
SCTE-R	30.83	-0.51	0.54	0.594

三种已发表方法均使用官方实现、在统一划分上训练与评估，肺叶掩膜由 TotalSegmentator 生成。图像质量最高的三种方法，定量一致性反而最低，三者方向一致。

本队列疾病负荷很低（参考 LAA-950 平均 1.21%），各方法的绝对误差差异均在 0.1 pp 量级；本表用于说明该缺口在低负荷基准上不可见，定量效应量以表 1 的临床队列为准。CCC 含受试者间方差，跨队列不可直接比较——本表与表 1 的 CCC 分母不同。

表 3 密度位移的直接测量（n = 444）

重建方式	整体密度位移 δ (HU)	说明
确定性回归	-16.32 ± 0.65	标准差 0.65 HU——是常数，不是噪声
纯标量偏置对照	-39.8 ~ -41.8	单纯平移不是解
SCTE-R	-1.76 ± 1.06	位移被消除

表 4 五肺叶分区一致性（站点适配臂，n = 444）

肺叶	左上	左下	右上	右中	右下
----	----	----	----	----	----

LAA-950 偏差 (pp) +0.84 +1.33 +0.85 +0.85 +1.50

LAA-950 CCC 0.951 0.929 0.949 0.956 0.954

五叶 CCC 均高于 0.92，支持区域性肺气肿评估，而不仅是全肺单一数值。

表 5 站点胜任度闸门（无参考，部署现场可计算）

域	模型是否学过该类数据	通过率	该域定量终点的实际表现
公开测试集	是	80%	正常
外部软核 CT	同核族	16.1%	正常（诊断分类改变率 1.6%）
外部锐核 CT	否	4.8%	失效（LAA-950 偏差 -4 ~ -5.5 pp）
同上，站点适配后	是	约 99%	恢复正常

关键在于：外部锐核数据本身处在物理标定集之内（标定集含 18 例同核样本），模型仍被判为不胜任——因此该判据反映的是"模型是否学过这类数据"，而不是"协议是否见过 这台设备"。标定扫描仪无法弥补模型的能力缺口，这正是部署闸门应有的语义。

三、这些结果能支撑论文吗

可以。按临床影像类期刊的标准衡量，以下几项构成充分基础：

- **外部验证规模合格。**444 例、两家厂商、两种重建核，且训练队列与验证队列来自 不同机构。该领域多数工作止步于单中心内部划分。
- **效应量大且方向一致。**LAA-950 偏差 -4.4 → -0.26 pp；Perc15 偏差 +23.5 → +2.5 HU；一致性界宽度缩小约一半。四个终点全部同向。
- **阴性对照在两个独立数据集上方向一致。**基线方法不改善定量一致性这一发现，在公开数据（三种方法均略差于插值）与临床队列（偏差差异 0.07 pp）上同向；效应量由 临床队列承担。
- **机制是测量出来的，不是推测的。**位移量的标准差 0.65 HU 使"这是一个常数"成为可检验的陈述。
- **区域分析完整。**五肺叶 CCC 0.93–0.96。

仍需补充的两项：

1. **5 mm 直接测量的基线行**。读者的第一个问题是"不做重建、直接在 5 mm 上测，偏差有多大"。该行是所有重建臂的真正对照，脚本已就绪（scripts/thick_baseline.py），在本地数据上运行即可补全。
2. **影像学阅片评价**。即本报告第四节所述的读片研究。现有证据全部是定量指标，补上阅片结果后，"可用于基层诊断"这一主张才真正闭合。

队列归属（正文须照此表述）。训练队列为 A 院 203 例（内部），验证队列为 B 院 494 例（外部），其中 50 例用于拟合协议常数与判据阈值、444 例用于上报。两个队列来自**不同医院**，模型在验证队列上从未见过任何配对数据，因此本文报告的是**外部验证**，而非内部划分。部分中间文档曾将两者统称为同一院名，正式稿中须按此更正。

四、阅片研究的设计建议

本项目已有一个别处少见的条件：**全部 444 例都存在真实的 1 mm 重建**。因此阅片研究不必依赖主观偏好比较，而可以用"与真实 1 mm 阅片结果的一致性"作为客观参照。

推荐设计：三臂阅片，以真实 1 mm 阅片为参照标准

臂	读什么	作用
A	原始 5 mm	现状（基层医院今天看到的）
B	SCTE-R 重建的 1 mm	本文方案
C	真实 1 mm	参照标准

核心假设：**B 的阅片结论与 C 的一致性，显著高于 A 与 C 的一致性**。这个设计绕开了"医生一眼能看出哪个是厚层"导致的盲法失败——因为衡量的不是医生偏好哪一张，而是结论是否更接近真值。

关键设计要点

- **洗脱期。**同一病例的不同臂至少间隔 2 周，且打乱顺序，避免记忆效应。
- **读者。**建议 3 名胸部影像医师独立阅片，报告读者间一致性。
- **病例数。**40–60 例即可支撑此类研究；建议按肺气肿负荷分层抽样，覆盖 无／轻／中／重四档，而不是随机抽（随机抽会有过半病例接近无病变，浪费读片量）。
- **记录内容。**①肺气肿有无及分级；②肺气肿分布类型（小叶中心型／全小叶型／间隔旁型）；③结节检出（位置、大小）；④诊断信心评分。

两个必须预设的终点

终点一（获益）：检出率提升。以 C 为真值，比较 A 与 B 的检出率——尤其是 5 mm 上容

易漏掉的小病灶。已有定量支持：在结节数据上，5 mm 只保留了 47% 的病灶对比度，且丢

失 31% 的 6 mm 以下结节；重建在零样本条件下回收了其中 70%。

终点二（安全）：不引入假阳性。统计"在 B 中被报告、但在 C 中不存在"的病灶数。这是重

建类方法最需要被质疑的地方，必须主动测量并报告。**建议把它 写成预先设定的主要安全终**

点，而不是事后补充的敏感性分析——主动量化比被动回答 更有说服力。

给医生的一句话说明

"这是同一次扫描的三种呈现：一种是设备直接输出的 5 mm，一种是由 5 mm 算法重建出的 1 mm，一种是设备直接输出的 1 mm。请按日常工作方式独立阅读并出具结论，不需要判断哪一张是算法生成的。"

五、口径说明

- 全部指标在整卷上计算，肺区由 TotalSegmentator 生成的肺叶掩膜界定，非基于 HU 窗。
- 一致性界 (limits of agreement) = 偏差 $\pm$ 1.96 SD，为 Bland-Altman 标准口径；CCC 为 Lin 一致性相关系数。
- 基线方法均使用作者公开的官方实现，在本项目统一划分上重新训练与评估。
- 训练队列（203 例）与验证队列（494 例 = 50 标定 + 444 上报）来自不同医院，构成真正的外部验证。
- "零样本"指直接使用公开数据训练的检查点，未接触本队列任何配对数据；"站点适配"指在本地配对数据上微调。基层部署对应前者，因为无薄层设备的医院不可能产生本地配对数据。
- 表 1 的 444 例与表 5 的分域计数一致：软核 311 例、锐核 126 例，另 7 例因肺区过小而弃权。